

TEMA 3

MÓDULO:
TÉCNICAS AVANZADAS DE
MACHINE LEARNING

DEEP LEARNING

ALBERTO JULIÁN RIGAU

Ingeniero Superior de Telecomunicaciones y MBA.



Institut de Formació Contínua-IL3
UNIVERSITAT DE BARCELONA

© de esta edición: Fundació IL3-UB, 2021

ÍNDICE

Objetivos Específicos

Deep Learning

Ideas clave



OBJETIVOS ESPECÍFICOS

- Comprender la diversidad de factores que han provocado la disrupción del Deep Learning.
- Practicar con arquitecturas de Deep Learning básicas.
- Asentar la base de Deep Learning necesaria para aplicar el Procesado de Imagen y el Procesado de Texto.

DEEP LEARNING

Deep Learning es un término acuñado por Geoffrey Hinton en 2006 para referirse a Redes Neuronales o NN (Neural Networks) compuestas por muchas capas. Como libro de referencia en el plano teórico, podemos considerar Goodfellow et al., 2016.

Podemos datar el segundo “invierno” de la IA desde mediados de la década de 1990 hasta 2010, aproximadamente. Sin embargo, a pesar de ser un período de contracción del interés en la IA, se siguieron produciendo avances en la base algorítmica del Deep Learning que explican en parte su auge actual.

Uno de los avances consistió en demostrar que el uso de **funciones de activación alternativas** a la sigmoide evitaba que el gradiente resultara fuera de rango, tanto por defecto (vanishing gradient) como por exceso (exploding gradient).

Por otra parte, se definió el modelo de red **LSTM** (Long Short-Term Memory), un tipo de Red Neuronal Recurrente o RNN con capacidad de retención (tutorial en Olah, 2015) y muy adecuada para procesamiento de texto. Su uso generalizado se produciría unos quince años más tarde.

En 2012, se publica un artículo describiendo el modelo AlexNet (Krizhevsky et al., 2012), que ganó la competición ImageNet Large-Scale Visual Recognition Challenge de 2012 (ILSVRC12), superando a modelos no basados en Redes Neuronales.

Desde entonces, ha comenzado a expandirse, de forma casi exponencial, el conocimiento y uso de las NN bajo la denominación Deep Learning. Entre los factores responsables de esta disrupción podemos mencionar:

- Mejoras algorítmicas.
- Mejoras en capacidad de cálculo.
- Posibilidad de entrenar con bancos masivos de imágenes.
- Difusión masiva del conocimiento.

Veremos ejemplos de uso tan variados como son la conducción autónoma, los asistentes de voz, los chatbots, la eficiencia energética en Data Centers o el diagnóstico precoz de cáncer.

Analizaremos distintas arquitecturas básicas de Redes Neuronales, como las Convolucionales (CNN) y las Recurrentes (RNN), y practicaremos estas arquitecturas en las áreas de Procesado de Imagen y Procesado de Lenguaje Natural.

Estas prácticas las haremos con los dos framework de Python más típicos, Tensorflow y Pytorch, en Google Colab.

Aprenderemos sobre modelos generativos, como:

- Las Redes Generativas Antagónicas o GAN.
- Los Auto Encoders.

A partir de este punto, vamos a continuar en Colab, herramienta con la que ya sabes trabajar.



IDEAS CLAVE

- Hay varios factores que explican la disrupción del Deep Learning, y varios no tienen que ver con algoritmia (a diferencia de las primeras evoluciones de las NN).
- Debe comprenderse que el Deep Learning continúa evolucionando y se introducirá en nuevas áreas.
- Sin embargo, no debe pensarse que el Deep Learning superará a todas las tecnologías actuales en esas nuevas áreas.